


Construction de graphe de pangénome locus-ciblé et détection de variations génomiques, Application aux génomes des Brassicacées

Introduction brève à la thématique

Un pangénome est défini comme la collection de séquences de génomes entiers provenant de multiples individus au sein d'un clade, d'une population ou d'une espèce. Cet ensemble de données peut être séparé en plusieurs groupes :


- Le génome **core** qui contient qui sont présent chez tous les individus impliqués dans les données du pangénome.
- Le génome accessoire pour lequel les gènes ne sont présents que chez certaines espèces et qui est subdivisé en deux groupes :
 - Le génome **shell** qui ne présente que des gènes présents chez une majorité d'individus et est de proportion deux fois plus importante que le génome core, présents sur de longues durées.
 - Le génome **cloud** qui consiste en un groupe de gènes présents uniquement dans un petit groupe d'individus, parfois uniquement chez un seul individu et soumis à un turnover rapide.



<https://theses.hal.science/tel-02933311v1>

Les graphes de pangénome représentent des pangénomes à l'aide de modèles graphiques, représentant les différentes variations le long des génomes. Ces graphes sont constitués de trois composantes :


- **Les nœuds** : des séquences d'ADN de longueur variable
- **Les arêtes** : représentent les liens entre deux nœuds
- **Les chemins** : chemins complets d'un nœud de l'extrémité d'un pangénome à un nœud de l'autre extrémité, passant à travers un set de nœuds défini.



1. [Introduction to pangenome graphs - Pangenome Graphs](#)

L'utilisation de ces graphes peut se faire dans le cadre d'une étude de pangénomique gène-centrée qui se concentre sur l'analyse des gènes et leurs variations pour étudier la diversité génétique au sein d'un groupe, souvent une espèce. Cette étude a plusieurs applications comme l'identification de certains gènes associés à des caractères phénotypiques d'intérêt et le développement de marqueurs moléculaires pour une sélection assistée par marqueurs.

Présentation de la démarche générale



Pipeline repris à partir de "Development of a pipeline for pan-genomic gene exploration : a case study of pea (Pisum sativum L.)" - Baptiste HERLEMONT

Jeux de données :

Guo, N., Wang, S., Wang, T., Duan, M., Zong, M., Miao, L., Han, S., Wang, G., Liu, X., Zhang, D., Jiao, C., Xu, H., Chen, L., Fei, Z., Li, J., & Liu, F. (2024). A graph-based pan-genome of Brassica oleracea provides new insights into its domestication and morphotype diversification. <i>Plant Communications</i> , 5(2), 100791. https://doi.org/10.1016/j.xplc.2023.100791					
Organisme : Brassica oleracea (wild cabbage)					
BioProject: PRJCA020663					
wild cabbage (W1701)	kohlrabi (PL021)	Broccoli (06-9-28)	kale (07-DH-33)	Brussels sprouts (D101)	Chinese kale (M249)
Génome : 640.8 Mo	Génome : 617 Mo	Génome : 599.5 Mo	Génome : 594.2 Mo	Génome : 625.8 Mo	Génome : 612.4 Mo
Chr 1 : 60.4	Chr 1 : 59.3	Chr1 : 58.5	Chr1 : 59.2	Chr1 : 60.6	Chr1 : 60.4

Outils :

Minimap2	Github	https://github.com/lh3/minimap2
	Référence bibliographique	Li, H. (2018). Minimap2 : pairwise alignment for nucleotide sequences. <i>Bioinformatics</i> , 34(18), 3094-3100. https://doi.org/10.1093/bioinformatics/bty191
SamTools	Github	https://github.com/samtools/
	Référence bibliographique	Li, H., Handsaker, B., Wysoker, A., Fennell, T., Ruan, J., Homer, N., Marth, G., Abecasis, G., & Durbin, R. (2009). The Sequence Alignment/Map format and SAMtools. <i>Bioinformatics</i> , 25(16), 2078-2079. https://doi.org/10.1093/bioinformatics/btp352
PGGB	Github	https://github.com/pangenome/pggb
	Référence bibliographique	Garrison, E., Guarracino, A., Heumos, S., Villani, F., Bao, Z., Tattini, L., Hagmann, J., Vorbrugg, S., Marco-Sola, S., Kubica, C., Ashbrook, D. G., Thorell, K., Rusholme-Pilcher, R. L., Liti, G., Rudbeck, E., Golicz, A. A., Nahnsen, S., Yang, Z., Mwaniki, M. N., . . . Prins, P. (2024). Building pangenome graphs. <i>Nature Methods</i> , 21(11), 2008-2012. https://doi.org/10.1038/s41592-024-02430-3
Minigraph-cactus	Github	https://github.com/ComparativeGenomicsToolkit/cactus/blob/master/doc/pangenome.md
	Référence bibliographique	Hickey, G., Monlong, J., Ebler, J. <i>et al.</i> Pangenome graph construction from genome alignments with Minigraph-Cactus. <i>Nat Biotechnol</i> 42 , 663–673 (2024). https://doi.org/10.1038/s41587-023-01793-w
Odgi	Github	https://github.com/pangenome/odgi
	Référence bibliographique	Andrea Guarracino, Simon Heumos, Sven Nahnsen, Pjotr Prins, Erik Garrison, ODGI: understanding pangenome graphs, <i>Bioinformatics</i> , Volume 38, Issue 13, July 2022, Pages 3319–3326, https://doi.org/10.1093/bioinformatics/btac308

Présentation des ressources de calcul et de stockage :

Outil	RAM requise	Stockage temporaire	Stockage final	Source
Minimap2	4-8 Gb	10 Gb	3-6 Gb	https://github.com/lh3/minimap2
Samtools	2-4 Gb	12 Gb	6 Gb	https://www.htslib.org/
Minicactus	16-32 Gb	50 – 100 Gb	5-10 Gb	https://github.com/ComparativeGenomicsToolkit/cactus
PGGB	64-128 Gb	100 – 200 Gb	5 – 15 Gb	https://github.com/pg-pangenomics/PGGB
Odgi	10-12 Gb	40 Gb	25 Gb	https://github.com/vgteam/odgi

Projet sur le cluster de l’IFB :

Project overview

Name

graphe_pangenome_brassicacees

Owner

nhnguyen97

Unix Group

Path

/shared/projects/graphe_pangenome_brassicacees

Size

385 GB

Cpu

10000 Hour

Creation

Nov 27, 2024

Expiration

Nov 27, 2025

Extend validity

Financing

Write permissions

Description

Construction d'un graphe pangénome de la famille des Brassicacées, mais centré sur l'utilisation d'un chromosome uniquement par génome. La construction de ce graphe serait basé sur les outils du début de Pipeline Panzone qui sont les suivants : Minimap2 SamTools PanGenomeGraphBuilder (PGGB) Minicactus2 Optionnellement Giraffe Je travaillerai sur un groupe d'un seul chromosome (75 Mb) par génome, pour un total de 6 génomes, soit 450 Mb au total. Le schéma de mon workflow est présent à cette adresse : Workflow graphe pangénome Brassicacées Concernant les spécificités de RAM et de stockage estimées pour chaque outil (précisées également sur le schéma), les voici : Minimap2 (RAM : 4-8 Gb / Stockage : 10 Gb) SamTools (RAM : 2-4 Gb / Stockage : 12 Gb) PanGenomeGraphBuilder (PGGB) (RAM : 64 -128 Gb / Stockage : 100 - 200 Gb Minicactus2 (RAM : 16-32 Gb / Stockage : 50 - 100 Gb) Giraffe (RAM : 10-15 Gb / Stockage : 20-50 Gb)

Tous les outils du tableau précédent sont installés.

Présentation des risques et difficultés potentielles :

- Lacunes et erreurs dans les fichiers de séquences : Certains fichiers fasta de génomes peuvent être mal annotés → les identifiants peuvent amener aux mauvais chromosomes, rendant l'extraction et l'alignement des chromosomes laborieuse.
- Coordination des étapes : Certaines étapes du workflow peuvent ne pas fonctionner correctement et produire en output des fichiers non viables qui bloquer ainsi la poursuite de ce dernier
- Réalisation des coordonnées de loci d'intérêt : dans les données utilisées initialement (utilisation de fichiers « DNA », il n'y a pas d'annotation des loci d'intérêt)


<https://pangenome.github.io>

<https://www.youtube.com/watch?app=desktop&v=fEYVFCTN0HY>


<https://www.sciencedirect.com/science/article/pii/S2211124723000037>

Avancée du projet


(Création de pipeline
avec Nextflow)



Exemple pour un des neuf outputs obtenus (Chromosome 5)




Multiqc_report.html :



Mean links length

For each path we iterate from node to node and count the node / nucleotide distance `mean_links_length` of nodes *within the same path only*. We then normalized by the path length.




ODGI Compressed 1D visualization

This image shows a 1D rendering of the built pangenome graph. The graph nodes are arranged from left to right, forming the pangenome sequence. Summarization of path coverage across all paths. A heatmap color-coding from <https://colorbrewer2.org/#type=diverging&scheme=RdBu&n=11> is used. Dark blue means highest coverage. Dark red means lowest coverage. The path names are placed on the left. The black lines under the paths are the links, which represent the graph topology.




ODGI 1D visualization

This image shows a 1D rendering of the built pangenome graph. The graph nodes are arranged from left to right, forming the pangenome sequence. The colored bars represent the paths versus the pangenome sequence in a binary matrix. The path names are placed on the left. The black lines under the paths are the links, which represent the graph topology.




ODGI 1D visualization by path position

This shows a 1D rendering of the built pangenome graph where the paths are colored according to their nucleotide position. Light grey means a low path position, black is the highest path position.




ODGI 1D visualization by path orientation

This image shows a 1D rendering of the built pangenome graph where the paths are colored by orientation. Forward is black, reverse is red.




ODGI 1D visualization by node depth

This shows a 1D rendering of the built pangenome graph where the paths are colored according to path depth. Using the Spectra color palette with 4 levels of path depths, white indicates no depth, while grey, red, and yellow indicate depth 1, 2, and greater than or equal to 3, respectively.




ODGI 1D visualization by uncalled bases

This shows a 1D rendering of the built pangenome graph where the paths are colored according to the coverage of uncalled bases. The lighter the green, the higher the 'N' content of a node is.



ODGI 2D drawing

This image shows a 2D rendering of the built pangenome graph.



Minigraph-cactus


cactus-pangenome /data/Jobstore_5 /data/seqfile_5.txt --outDir /data/resultCactus05 --outName Chr5 --reference GWHEQVE5 --viz

fichier seqfile_5.txt


```
1 GWHEQVE5 /data/chromosomes/chromosome_C5/GWHEQVE00000005.fasta
2 GWHEQVJ5 /data/chromosomes/chromosome_C5/GWHEQVJ00000005.fasta
3 GWHEQVL5 /data/chromosomes/chromosome_C5/GWHEQVL00000007.fasta
4 GWHEQVM5 /data/chromosomes/chromosome_C5/GWHEQVM00000005.fasta
5 GWHEQVN5 /data/chromosomes/chromosome_C5/GWHEQVN00000005.fasta
6 GWHEQV05 /data/chromosomes/chromosome_C5/GWHEQV00000007.fasta
```

Exemple de résultats

PGGB



Minigraph-cactus



La différence entre les deux graphes peuvent s’expliquer par les méthodes de construction de graphe utilisées par les deux outils :

Minigraph-Cactus utilise **Minigraph** pour aligner rapidement de nouvelles séquences sur un génome de référence, en privilégiant une structure linéaire et en minimisant les insertions de nouvelles branches.

Cactus génère un alignement évolutif basé sur une phylogénie, ce qui permet une structuration plus hiérarchique et moins fragmentée du graphe.

PGGB effectue un **alignement multiple global**, ce qui permet une représentation plus détaillée et dense des variations. Il applique des étapes de **lissage et de simplification** (via ODGI et Smoothxg), ce qui réduit les redondances mais peut aussi complexifier visuellement la structure.

Caractéristique	Minigraph-Cactus	PGGB
Structure globale	Plus linéaire et compacte	Très dense et ramifiée
Gestion des variations	Capture les grandes variations et les SV majeures	Capture des SNP, Indels et SV détaillées.
Complexité visuelle	Moins de connexions entre les nœuds, graphe plus simple	Fort enchevêtrement, reflet d’un alignement détaillé
Possibilité d’incrémentation	Oui, on peut ajouter de nouveaux génomes sans tout reconstruire	Non, nécessite un recalcul complet en cas d’ajout
Niveau de détail	Moins précis sur les variations fines	Très précis et exhaustif

Explication des différences spécifiques observées

- **Moins de connexions dans Minigraph-Cactus** : alignement guidé par un génome de référence, ce qui évite la prolifération des nœuds superflus.
- **Plus de connexions et d’entrelacements dans PGGB** : aligne toutes les séquences simultanément et représente davantage de petites variations (SNPs, petits indels), ce qui rend le graphe plus complexe.
- **Noeuds épais dans PGGB** : régions avec beaucoup de variations et des chemins alternatifs dans le graphe.

Graphe évolutif, compact et évolutif → Minigraph-Cactus

Graphe ultra-détaillé et normalisé pour des analyses précises des variations génétiques (SNPs, indels, SV) → PGGB


Transfert d'annotations de GFF de génome de référence à un graphe de pangénome :



<https://forge.ird.fr/diade/dynadiv/grannot>

grannot **graph.gfa** **annotation.gff** **source_genome** -gff

Visualisation de variations et d'annotations



Feature details

Core details

Position	GWHEQVE00000005:37,872,221
Description	SNV A → G
Name	>1667767>1667770
Length	1
Type	SNV

Attributes

CHROM	GWHEQVE000000005
POS	37872221
INFO.AC	4
INFO.AF	0.8
INFO.AN	5
INFO.AT	>1667767>1667768>1667770

>1667767>1667769>1667770

INFO.NS	5
INFO.LV	1
INFO.PS	>338772>3037801
REF	A
ID	>1667767>1667770
QUAL	60
FORMAT	GT

SHOW FEATURE SEQUENCE

SAMPLES

☒ Show options

These filters can use a plain text search or regex style query, e.g. in the genotype field, entering 1 will query for all genotypes that include the first alternate allele e.g. 0|1 or 1|1, entering [1-9]\d* will find any non-zero allele e.g. 0|2 or 2/33

Filter sample

Filter GT

Columns	Filters	Density	Export
sample	GT		
GWHEQVJ000000005	0		
GWHEQVL000000007	1		
GWHEQVM000000005	1		
GWHEQVN000000005	1		
GWHEQVO000000007	1		